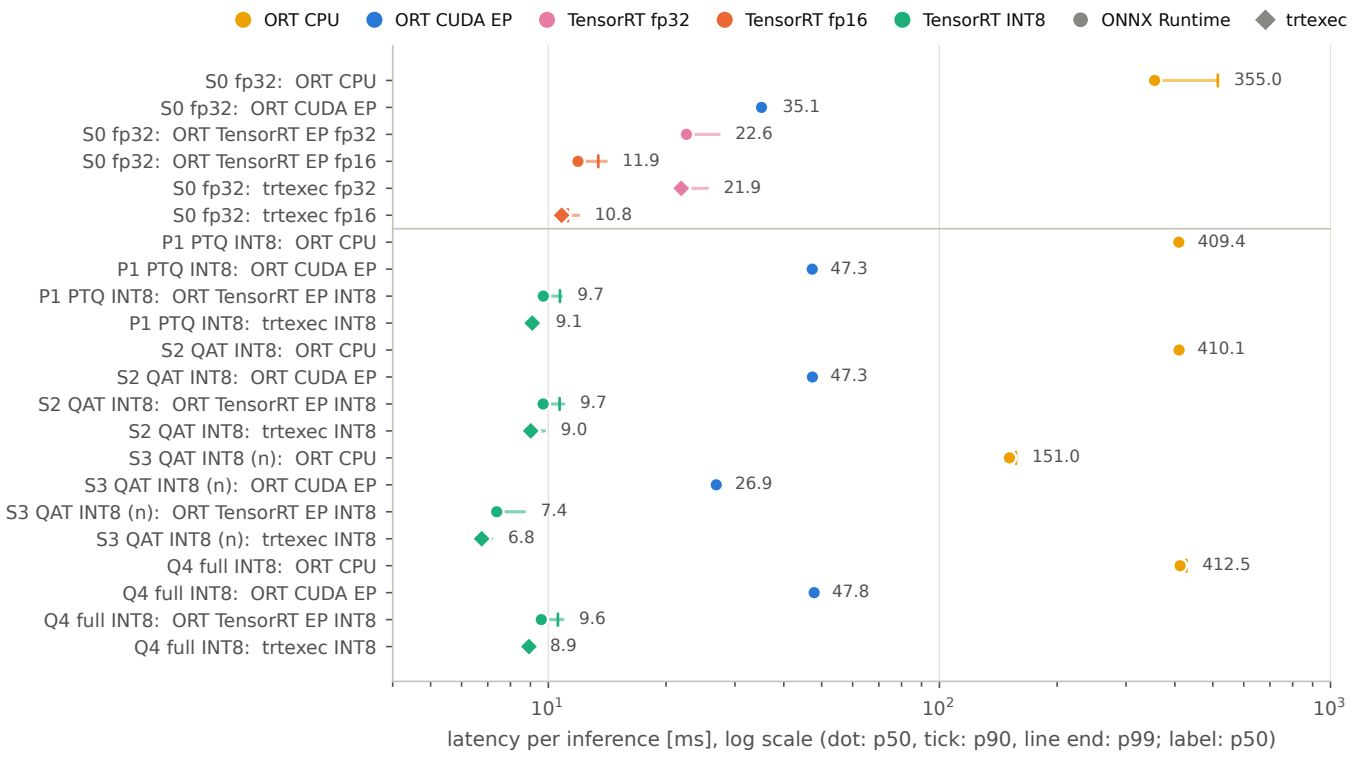
ORT CPU
ORT CUDA EP
TensorRT fp32
TensorRT fp16
TensorRT INT8
ONNX Runtime
trtexec
S0 fp32: ORT CPU
S0 fp32: ORT CUDA EP
S0 fp32: ORT TensorRT EP fp32
S0 fp32: ORT TensorRT EP fp16
S0 fp32: trtexec fp32
S0 fp32: trtexec fp16
P1 PTQ INT8: ORT CPU
P1 PTQ INT8: ORT CUDA EP
P1 PTQ INT8: ORT TensorRT EP INT8
P1 PTQ INT8: trtexec INT8
S2 QAT INT8: ORT CPU
S2 QAT INT8: ORT CUDA EP
S2 QAT INT8: ORT TensorRT EP INT8
S2 QAT INT8: trtexec INT8
S3 QAT INT8 (n): ORT CPU
S3 QAT INT8 (n): ORT CUDA EP
S3 QAT INT8 (n): ORT TensorRT EP INT8
S3 QAT INT8 (n): trtexec INT8
Q4 full INT8: ORT CPU
Q4 full INT8: ORT CUDA EP
Q4 full INT8: ORT TensorRT EP INT8
Q4 full INT8: trtexec INT8
355.0
35.1
22.6
11.9
21.9
10.8
409.4
47.3
9.7
9.1
410.1
47.3
9.7
9.0
151.0
26.9
7.4
6.8
412.5
47.8
9.6
8.9
10^1
10^2
10^3
latency per inference [ms], log scale (dot: p50, tick: p90, line end: p99; label: p50)